

# Einführung in die angewandte Stochastik

## 6. Globalübung - Lösungen

### Aufgabe 28

- (a) Seien  $x_1, \dots, x_n \in (1, \infty)$  Realisationen der laut Aufgabenstellung gegebenen Zufallsvariablen  $X_1, \dots, X_n$ .

Dann ist die zugehörige Likelihood-Funktion gemäß B 3.12 und D 3.2 gegeben durch:

$$L(\alpha | x_1, \dots, x_n) \stackrel{\text{Unabh.}}{=} \prod_{i=1}^n f_\alpha(x_i) \stackrel{\text{Def. } f_\alpha}{=} \prod_{i=1}^n \frac{\alpha}{x_i^{\alpha+1}} = \alpha^n \prod_{i=1}^n x_i^{-(\alpha+1)}, \quad \alpha \in (0, \infty). \quad (1)$$

Die zugehörige Log-Likelihood-Funktion ist gegeben durch:

$$\begin{aligned} \ell(\alpha) &= \ln \left( L(\alpha | x_1, \dots, x_n) \right) \stackrel{(1)}{=} \ln \left( \alpha^n \prod_{i=1}^n x_i^{-(\alpha+1)} \right) \\ &= \ln(\alpha^n) + \sum_{i=1}^n \ln(x_i^{-(\alpha+1)}) = n \ln(\alpha) - (\alpha + 1) \sum_{i=1}^n \ln(x_i), \quad \alpha \in (0, \infty). \quad (2) \end{aligned}$$

Gemäß (2) ist  $\ell$  differenzierbar auf  $(0, \infty)$  mit:

$$\begin{aligned} \ell'(\alpha) &= \frac{n}{\alpha} - \sum_{i=1}^n \ln(x_i) \left\{ \begin{array}{c} > \\ = \\ < \end{array} \right\} 0 \\ &\iff \frac{n}{\alpha} \left\{ \begin{array}{c} > \\ = \\ < \end{array} \right\} \underbrace{\sum_{i=1}^n \ln(x_i)}_{> 0 \text{ da } x_1, \dots, x_n > 1} \iff \alpha \left\{ \begin{array}{c} < \\ = \\ > \end{array} \right\} \frac{n}{\underbrace{\sum_{i=1}^n \ln(x_i)}_{=: \hat{\alpha}}}. \quad (3) \end{aligned}$$

Aus (3) folgt, dass  $\ell$  streng monoton wachsend auf  $(0, \hat{\alpha}]$  und streng monoton fallend auf  $[\hat{\alpha}, \infty)$  ist.

Somit besitzt die Log-Likelihood-Funktion  $\ell$  und damit auch die Likelihood-Funktion  $\alpha \mapsto L(\alpha | x_1, \dots, x_n)$  selbst ein eindeutig bestimmtes globales Maximum in  $\hat{\alpha}$ .

D.h.: Eine Maximum-Likelihood-Schätzung für den unbekannten Parameter  $\alpha$  ist gegeben durch

$$\hat{\alpha} = \frac{n}{\sum_{i=1}^n \ln(x_i)}.$$

Ebenso wie in den Beispielen der Vorlesung ist die Maximum-Likelihood-Schätzung auch hier sogar eindeutig bestimmt, d.h. weitere Maximum-Likelihood-Schätzungen für  $\alpha$  existieren nicht.

- (b) Es bezeichnen  $x_1, \dots, x_{12}$  die  $n = 12$  gegebenen Datenwerte. Einsetzen dieser Daten liefert folgenden Schätzwert für  $\alpha$ :

$$\hat{\alpha} \stackrel{(a)}{=} \frac{12}{\sum_{i=1}^{12} \ln(x_i)} \approx 0,903.$$

- (c) Mittels Ersetzen des unbekannten Parameters  $\alpha$  durch den in (b) berechneten Schätzwert  $\hat{\alpha} \approx 0.903$  erhält man folgende Wahrscheinlichkeit:

$$P_{\hat{\alpha}}(X_1 > 2) = 1 - P_{\hat{\alpha}}(X_1 \leq 2) = 1 - F_{\hat{\alpha}}(2) \stackrel{\text{Eins.}}{\approx} 1 - \left(1 - \frac{1}{2^{0.903}}\right) \approx 0,535.$$

### Wirtschaftswissenschaftlicher Hintergrund zu Aufgabe 28

Der Schweizer Wirtschaftswissenschaftler *Vilfredo Pareto* formulierte 1897 die empirisch begründete These, dass der Anteil der Personen in einer Volkswirtschaft, die ein Einkommen von mindestens  $x$  haben, (ungefähr)  $(\beta/x)^\alpha$  beträgt, wobei der Parameter  $\beta$  hierbei als Mindesteinkommen interpretiert wird und  $\alpha > 0$  die sogenannte *Pareto-Konstante* ist.

Wird bei gegebenen Parametern  $\alpha, \beta$  das Einkommen einer zufällig aus der Volkswirtschaft ausgewählten Person durch die Zufallsvariable  $X$  mit (stetiger) Verteilungsfunktion  $F$  beschrieben, gilt gemäß dieses Ansatzes:

$$P(X \geq x) = \begin{cases} \left(\frac{\beta}{x}\right)^\alpha, & x \geq \beta, \\ 1, & x < \beta, \end{cases} \iff F(x) = P(X \leq x) = \begin{cases} 1 - \left(\frac{\beta}{x}\right)^\alpha, & x \geq \beta, \\ 0, & x < \beta. \end{cases}$$

Normiert man das Mindesteinkommen zu 1, d.h. für  $\beta = 1$  ergibt sich gerade die in der Aufgabenstellung zu Aufgabe 28 angegebene Pareto-Verteilung mit Verteilungsfunktion

$$F_\alpha(x) = \begin{cases} 1 - \frac{1}{x^\alpha}, & x \geq 1, \\ 0, & x < 1, \end{cases}$$

in Abhängigkeit vom (dann einzigen) Parameter  $\alpha > 0$ .

Vor diesem Hintergrund sind die in Aufgabe 28(b) angegebenen Daten als Vielfache des Mindesteinkommens zu interpretieren. Legt man beispielsweise ein Mindesteinkommen von 500 € zugrunde, ergeben sich aus diesen Daten die folgenden 12 Einkommenswerte (in €):

825, 1485, 1760, 1535, 1030, 1205, 1920, 2740, 930, 2450, 3680, 790.

In Aufgabe 28(c) wird (mittels der Parameterschätzung  $\hat{\alpha} = 0.903$ ) somit die Wahrscheinlichkeit berechnet, mit der das Einkommen einer zufällig ausgewählten Person das Doppelte des Mindesteinkommens übersteigt.

## Aufgabe 29

### Modell:

Die Auslastungen der Flüge können beschrieben werden durch stochastisch unabhängige, identisch verteilte Zufallsvariablen  $X_1, \dots, X_n$  mit folgender Interpretation für  $i \in \{1, \dots, n\}$ :

$$X_i = \begin{cases} 1, & \text{falls der } i\text{-te Passagier den Flug **nicht** antritt,} \\ 0, & \text{falls der } i\text{-te Passagier den Flug antritt.} \end{cases}$$

(Hierbei wird angenommen, dass die Entscheidungen der Passagiere, den Flug anzutreten/nicht anzutreten, unabhängig voneinander erfolgen.)

Mit dieser Festlegung der Zufallsvariablen  $X_1, \dots, X_n$  gilt dann:

$$X_i \sim \text{bin}(1, p) \quad \text{für } i \in \{1, \dots, n\},$$

wobei  $p \in (0, 1)$  die unbekannte Wahrscheinlichkeit bezeichnet, mit der ein zufällig ausgewählter Passagier seinen Flug **nicht** antritt.

Gemäß D 4.5 ist in dieser Situation ein zweiseitiges (symmetrisches) *approximatives* Konfidenzintervall für den Parameter  $p$  zum Konfidenzniveau  $1 - \alpha$  gegeben durch:

$$K = \left[ \hat{p} - \frac{u_{1-\frac{\alpha}{2}}}{\sqrt{n}} \sqrt{\hat{p}(1-\hat{p})}, \hat{p} + \frac{u_{1-\frac{\alpha}{2}}}{\sqrt{n}} \sqrt{\hat{p}(1-\hat{p})} \right].$$

Hierbei bezeichnen (mit  $x_1, \dots, x_n$  als Realisationen von  $X_1, \dots, X_n$ )

$$\hat{p} = \bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

die (erwartungstreue) Maximum-Likelihood-Schätzung für den unbekannten Parameter  $p$  und  $u_{1-\frac{\alpha}{2}} = \Phi^{-1}(1 - \frac{\alpha}{2})$  das  $(1 - \frac{\alpha}{2})$ -Quantil zu  $N(0, 1)$ .

### Einsetzen der Zahlenwerte:

Mit  $1 - \alpha = 0,9 \iff \alpha = 0,1 \iff 1 - \frac{\alpha}{2} = 0,95$  erhält man aus der Quantiltabelle der Standardnormalverteilung:

$$u_{1-\frac{\alpha}{2}} = u_{0,95} = \Phi^{-1}(0,95) \stackrel{\text{Tab.}}{\approx} 1,64.$$

Dies ergibt zusammen mit  $n = 1000$  und

$$\hat{p} = \bar{x} \stackrel{\text{Vor.}}{=} \frac{74}{1000} = 0,074$$

das folgende zweiseitige approximative 90%-Konfidenzintervall für  $p$ :

$$K \approx \left[ 0,074 - 1,64 \cdot \sqrt{\frac{0,074 \cdot 0,926}{1000}}, 0,074 + 1,64 \cdot \sqrt{\frac{0,074 \cdot 0,926}{1000}} \right] \approx [0,060, 0,088].$$

## Aufgabe 30

- (a) Gemäß D 5.8 ist unter der vorausgesetzten Normalverteilungsannahme mit *unbekannter* Varianz  $\sigma^2$  ein zweiseitiges (symmetrisches) Konfidenzintervall für den Erwartungswert  $\mu$  zum Konfidenzniveau  $1 - \alpha$  gegeben durch:

$$K_1 = \left[ \bar{x} - t_{1-\frac{\alpha}{2}}(n-1) \frac{\hat{\sigma}}{\sqrt{n}}, \bar{x} + t_{1-\frac{\alpha}{2}}(n-1) \frac{\hat{\sigma}}{\sqrt{n}} \right].$$

Hierbei bezeichnen

$$\hat{\sigma}^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2 = \frac{1}{n-1} \left( \sum_{i=1}^n x_i^2 - n \bar{x}^2 \right)$$

die Stichprobenvarianz zu den Daten  $x_1, \dots, x_n$  und  $t_{1-\frac{\alpha}{2}}(n-1)$  das  $(1 - \frac{\alpha}{2})$ -Quantil zur  $t$ -Verteilung mit  $n - 1$  Freiheitsgraden.

### Einsetzen der Zahlenwerte:

Mit  $n = 12$  und  $1 - \alpha = 0,9 \iff \alpha = 0,1 \iff 1 - \frac{\alpha}{2} = 0,95$  erhält man aus der Quantiltabelle der  $t$ -Verteilung:

$$t_{1-\frac{\alpha}{2}}(n-1) = t_{0,95}(11) \stackrel{\text{Tab.}}{\approx} 1,796.$$

Weiter berechnet man aus den gegebenen Daten  $x_1, \dots, x_{12}$ :

$$\bar{x} = \frac{1}{12} \sum_{i=1}^{12} x_i \approx 3,528 \quad \text{und} \quad \hat{\sigma} = \sqrt{\frac{1}{11} \left( \sum_{i=1}^{12} x_i^2 - 12 \cdot \bar{x}^2 \right)} \approx 0,185.$$

Hiermit erhält man das folgende zweiseitige 90%-Konfidenzintervall für  $\mu$  bei *unbekannter* Varianz  $\sigma^2$ :

$$K_1 \approx \left[ 3,528 - 1,796 \cdot \frac{0,185}{\sqrt{12}}, 3,528 + 1,796 \cdot \frac{0,185}{\sqrt{12}} \right] \approx [3,432, 3,624].$$

- (b) Gemäß D 5.6 ist unter der vorausgesetzten Normalverteilungsannahme mit *bekannter* Varianz  $\sigma^2$  ein zweiseitiges (symmetrisches) Konfidenzintervall für den Erwartungswert  $\mu$  zum Konfidenzniveau  $1 - \alpha$  gegeben durch:

$$K_2 = \left[ \bar{x} - u_{1-\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}}, \bar{x} + u_{1-\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}} \right].$$

Hierbei bezeichnet  $u_{1-\frac{\alpha}{2}} = \Phi^{-1}(1 - \frac{\alpha}{2})$  das  $(1 - \frac{\alpha}{2})$ -Quantil zur Standardnormalverteilung  $N(0, 1)$ .

### Einsetzen der Zahlenwerte:

Mit  $1 - \frac{\alpha}{2} \stackrel{(a)}{=} 0,95$  erhält man aus der Quantiltabelle der Standardnormalverteilung:

$$u_{1-\frac{\alpha}{2}} = u_{0,95} = \Phi^{-1}(0,95) \stackrel{\text{Tab.}}{\approx} 1,64.$$

Dies ergibt zusammen mit  $n = 12$ ,  $\bar{x} \stackrel{(a)}{\approx} 3,528$  und

$$\sigma = \sqrt{\sigma^2} \stackrel{\text{Vor.}}{=} \sqrt{0,0324} = 0,18$$

bei *bekannter* Varianz  $\sigma^2 = 0,0324$  das folgende zweiseitige 90%-Konfidenzintervall für  $\mu$ :

$$K_2 \approx \left[ 3,528 - 1,64 \cdot \frac{0,18}{\sqrt{12}}, 3,528 + 1,64 \cdot \frac{0,18}{\sqrt{12}} \right] \approx [3,443, 3,613].$$

### Bemerkung zu Aufgabe 30 (a) und (b)

Da hier  $\hat{\sigma} \approx \sigma$  und  $t_{0,95}(11) \approx u_{0,95}$  gilt, unterscheiden sich die beiden berechneten Konfidenzintervalle  $K_1$  und  $K_2$  nur geringfügig.

- (c) Wie bereits in (b) angegeben, ist unter der vorausgesetzten Normalverteilungsannahme mit *bekannter* Varianz  $\sigma^2$  ein zweiseitiges (symmetrisches) Konfidenzintervall für den Erwartungswert  $\mu$  zum Konfidenzniveau  $1 - \alpha$  für  $n \in \mathbb{N}$  Beobachtungen gegeben durch:

$$K(n) = \left[ \bar{x} - u_{1-\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}}, \bar{x} + u_{1-\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}} \right]. \quad (1)$$

Sei  $l > 0$  eine vorgegebene maximale Intervalllänge. Dann gilt für die Intervalllänge  $L(K(n))$  des Konfidenzintervalls  $K(n)$ :

$$\begin{aligned} L(K(n)) &\stackrel{(1)}{=} \bar{x} + u_{1-\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}} - \left( \bar{x} - u_{1-\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}} \right) = 2 u_{1-\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}} \leq l \\ \iff \sqrt{n} &\geq \frac{2 u_{1-\frac{\alpha}{2}} \sigma}{l} \\ \iff n &\geq \left( \frac{2 u_{1-\frac{\alpha}{2}} \sigma}{l} \right)^2 = \frac{4 \sigma^2 u_{1-\frac{\alpha}{2}}^2}{l^2}. \end{aligned} \quad (2)$$

### Einsetzen der Zahlenwerte:

Mit  $l = 0,1$ ,  $\sigma^2 = 0,0324$  und  $u_{1-\frac{\alpha}{2}} = u_{0,95} \stackrel{(b)}{\approx} 1,64$  erhält man aus (2):

$$n \geq \frac{4 \cdot 0,0324 \cdot 1,64^2}{0,1^2} \approx 34,86.$$

Wegen  $n \in \mathbb{N}$  müssen somit mindestens  $n = 35$  Versuchsflächen vorhanden sein, um bei *bekannter* Varianz  $\sigma^2 = 0,0324$  ein zweiseitiges 90%-Konfidenzintervall für den Erwartungswert  $\mu$  mit einer maximalen Länge von  $l = 0,1$  ( $t$ ) angeben zu können.

## Aufgabe 31

Gemäß D 5.13 ist ein zweiseitiges (symmetrisches) Konfidenzintervall für  $d = \mu_1 - \mu_2$  zum Konfidenzniveau  $1 - \alpha$  bei unbekannter (gleicher) Varianz  $\sigma^2$  gegeben durch

$$K = \left[ \hat{\Delta} - t_{1-\frac{\alpha}{2}}(n_1 + n_2 - 2) \hat{\sigma}_{\text{pool}} \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}, \hat{\Delta} + t_{1-\frac{\alpha}{2}}(n_1 + n_2 - 2) \hat{\sigma}_{\text{pool}} \sqrt{\frac{1}{n_1} + \frac{1}{n_2}} \right].$$

Hierbei bezeichnen  $\hat{\Delta} = \bar{x} - \bar{y}$  die erwartungstreue Punktschätzung für  $d = \mu_1 - \mu_2$ ,

$$\begin{aligned} \hat{\sigma}_{\text{pool}}^2 &= \frac{1}{n_1 + n_2 - 2} \left( \underbrace{\sum_{i=1}^{n_1} (x_i - \bar{x})^2}_{=(n_1-1)\hat{\sigma}_1^2} + \underbrace{\sum_{j=1}^{n_2} (y_j - \bar{y})^2}_{=(n_2-1)\hat{\sigma}_2^2} \right) \\ &= \frac{(n_1 - 1)\hat{\sigma}_1^2 + (n_2 - 1)\hat{\sigma}_2^2}{n_1 + n_2 - 2} \end{aligned}$$

den erwartungstreuen Punktschätzer für  $\sigma^2$  kombiniert aus beiden vorliegenden Stichproben und  $t_{1-\frac{\alpha}{2}}(n_1 + n_2 - 2)$  das  $(1 - \frac{\alpha}{2})$ -Quantil der  $t$ -Verteilung mit  $n_1 + n_2 - 2$  Freiheitsgraden.

### Einsetzen der Zahlenwerte:

Mit  $n_1 = 12$ ,  $n_2 = 8$ ,  $1 - \alpha = 0,95 \iff 1 - \frac{\alpha}{2} = 0,975$  erhält man aus der Quantiltabelle der  $t$ -Verteilung:

$$t_{1-\frac{\alpha}{2}}(n_1 + n_2 - 2) = t_{0,975}(18) \stackrel{\text{Tab.}}{\approx} 2,101.$$

Aus den Messwerten  $x_1, \dots, x_{12}$  und  $y_1, \dots, y_8$  berechnet man:

$$\begin{aligned} \bar{x} &= \frac{1}{12} \sum_{i=1}^{12} x_i = 50,4, \quad \bar{y} = \frac{1}{8} \sum_{i=1}^8 y_i = 50,6, \quad \hat{\Delta} = \bar{x} - \bar{y} = -0,2, \\ \hat{\sigma}_1^2 &= \frac{1}{11} \sum_{i=1}^{12} (x_i - \bar{x})^2 \approx 4,433, \quad \hat{\sigma}_2^2 = \frac{1}{7} \sum_{j=1}^8 (y_j - \bar{y})^2 \approx 3,326, \\ \hat{\sigma}_{\text{pool}} &\approx \sqrt{\frac{11 \cdot 4,433 + 7 \cdot 3,326}{18}} \approx 2,0006. \end{aligned}$$

Hiermit erhält man:

$$\begin{aligned} K &\approx \left[ -0,2 - 2,101 \cdot 2,0006 \cdot \sqrt{\frac{1}{12} + \frac{1}{8}}, -0,2 + 2,101 \cdot 2,0006 \cdot \sqrt{\frac{1}{12} + \frac{1}{8}} \right] \\ &\approx [-2,119, 1,719]. \end{aligned}$$